

A Neural Network Model with Gap Junction for Global Feature Extraction

郑晖

日期：2021 年 5 月 10 日

摘 要

A Neural Network Model with Gap Junction for Global Feature Extraction.

关键词：Gap Junction, Global Feature Extraction

1 Introduction

2 Materials & Methods

我们考虑一维环状网络模型??，该网络在 E/I 平衡网络 [?] 之上修改而来。在这个一维环状网络中，E 型神经元和 I 型神经元分别被用来建模 ipRGC 和 PAC。




图 1: The neural network model

2.1 Neuronal Dynamics

简便起见，模型中的所有神经元都使用 LIF 模型实现。所有神经元都接受来自外界的输入，其中 I 型神经元的外界输入只有双极细胞输入，而 E 型神经元的外界输入可以分为两部分：双

极细胞输入和黑色素输入。双极细胞输入由于生物神经元结构相对黑色素输入有一定延迟，但这一点暂时没有被我们初步的模型所考虑。环上每一个神经元都与相邻的 n 个神经元形成电突触连接，每个 I 型神经元都与相邻的 m 个 E 神经元形成抑制性 Exponential 化学突触连接。

I 型神经元的动力学机制如下：

$$\tau \frac{dV_i(t)}{dt} = -V_i(t) + \sum_{j \in N_G(i)} I_{ij}^{gap}(t) + I_i^{ext}(t) \quad (1)$$

其中，下标 $i = (1, \dots, N)$ 表示神经元的索引， V_i 表示神经元的膜电位， τ 表示膜时间常数， I_{ij}^{gap} 表示从神经元 j 通过 gap junction 传递而来的电流， $N_G(i)$ 表示与神经元 i 具备电突触连接的神经元集合， I_{ext} 表示外部输入的刺激。无论何时 $V_i(t)$ 到达一个固定的阈值 V_{th} ，神经元便会产生一个 spike，然后将自身膜电位复位到 V_{rest} 并进入时长为 τ^{arp} 的不应期。在仿真开始前，所有神经元的膜电位被随机初始化。

E 型神经元的动力学机制与 I 型神经元略有差异，多了来自 I 型神经元的抑制输入，其表达式如下：

$$\tau \frac{dV_i(t)}{dt} = -V_i(t) + \sum_{j \in N_G(i)} I_{ij}^{gap}(t) - I_i^{chem}(t) + I_i^{ext}(t) \quad (2)$$

其中， $I_i^{chem}(t)$ 表示神经元 i 通过抑制性化学突触接收到的电流，其他参数与 I 型神经元动力学机制中对应参数意义相同。

由电突触介导的电流可以分成两部分：

$$I_{ij}^{gap}(t) = I_{ij}^{gap,sub}(t) + I_{ij}^{gap,sup}(t) \quad (3)$$

其中， $I_{ij}^{gap,sub}$ 表示阈下电流， $I_{ij}^{gap,sup}$ 表示阈上电流，被称作 spikelet。由电突触介导的阈下电流如下：

$$I_{ij}^{gap,sub} = J[V_j(t) - V_i(t)] \quad (4)$$

其中， J 表示耦合强度。阈上电流被假设与 gap junction 强度 J 成正比，并由 spikelet 因子 γ 缩放，其表达式如下：

$$I_{ij}^{gap,sup}(t) = \gamma J \delta(t - t_j^{spike}) \quad (5)$$

其中， t_j^{spike} 表示神经元 j 产生 spike 的时刻， γ 量化 spike 对神经元膜电位增加量的贡献。

由 Exponential 化学突触介导的电流动力学机制（current-based）如下：

$$I_i^{chem}(t) = \bar{g}s_i(t) \quad (6)$$

$$\frac{ds_i}{dt} = -\frac{s_i}{\tau_{decay}} + \sum_{j \in N_C(i)} \delta(t - t_j^{spike}) \quad (7)$$

其中， \bar{g} 表示化学突触平均电导， τ_{decay} 表示衰减时间常数， $N_C(i)$ 表示与神经元 i 具备抑制性化学突触连接的神经元集合， t_j^{spike} 表示神经元 j 产生 spike 的时刻。

外部输入电流 I_i^{ext} ，携带着图像的亮度信息。其被建模为带有高斯白噪音的连续电流：

$$I_i^{ext}(t) = \mu_i^{ext} + \sigma^2 \eta_i(t) \quad (8)$$

其中， μ^{ext} 是外部输入的平均值， σ^2 是外部输入震荡的幅度， $\eta_i(t)$ 满足 $\langle \eta_i(t) \rangle = 0$ ，并且 $\langle \eta_i(t) \eta_j(t') \rangle = \delta_{ij} \delta(t - t')$ 。通常情况下，幅度 σ^2 在我们的模拟中被设为一个恒定值，大概是外部平均输入的 10%。值得注意的是，E 型神经元的外部输入平均值 μ_E^{ext} 略大于 I 型神经元

的外部输入平均值 μ_I^{ext} 。其原因在于 E 型神经元是对 ipRGC 进行建模，ipRGC 不仅接受双极细胞的输入（PAC 仅有的外部输入），还接受自身黑色素产生的感光输入。

3 Results

3.1 Non-Normalization

在该实验中，我们将光强设置为 [12,0,12] 序列（其中刺激为 10 时将激发神经元，与神经元的 V_{th} 相对应），没有添加输入噪声。模型结构上，未将突触的输入进行归一化。例如，一个神经元接受 10 个神经元的兴奋性输入，我们只是将其单纯地累加，没有将其除以 10。其余结构不变。在神经元初始化时，我们使用 Gaussian 随机初始化。

3.1.1 PAC 的抑制性化学突触近邻范围影响光自适应速度

在我们将 es_neighbors 设置为 5 时，ipRGC 的发放很快便被抑制，如图??。当 es_neighbors 被设置为 3 时，ipRGC 的发放会持续更长的一段时间，如图??。




图 2: fig:101-es5-w3.5

3.2 Normalization

在实验中我们使用 μ^{ext} 为 9、 σ 为 0.2 的高斯分布输入刺激 I^{ext} 。模型结构上，将突触的输入进行归一化。例如，一个神经元接受 10 个神经元的兴奋性输入，我们在将其累加后除以 10。其余结构不变。在这项实验中可以调节的参数有 $weight_{ES}$ 、 $neighbors_{ES}$ 、 $weight_{GJ}$ 、 $neighbors_{GJ}$ 。其余参数不变的原因如下：

- $shape_{ipRGC}$ & $shape_{PAC}$: 我将其分别取值为 50、100。由于 GJ 和 ES 都是局部的，只要 $shape_{ipRGC}$ & $shape_{PAC}$ 足够大，发放模式便与之无关。
- V_{reset} & V_{th} & V_{init} : 这些参数与刺激呈线性关系，由于刺激已经被固定，这些参数对于发放模式没有意义。




图 3: fig:101-es3-w3.5

- τ & $t_{refractory}$: 只会影响衰减的速率, 由于刺激时长已经固定, 不需要进行修改。
- $k_{spikelet}$: 该参数与 $weight$ 起到相同的作用, 没有调节该参数的必要。
- $delay_{ES}$ & τ_{ES} : 与神经元的衰减参数相对应。或许, 以后实验应该将神经元的 τ 固定, 修改该参数相对其的比例, 查看效果。

3.2.1 $neighbors_{ES}$ 、 $weight_{ES}$ 影响发放间隔

$neighbors_{ES}$ 、 $weight_{ES}$ 会影响神经元的发放间隔, 其中这里主要影响的是输入在阈值 10 以下的神经元, 对于输入在 10 以上的神经元基本没有影响。而且这种影响比较 general, 在 $weight_{GJ}$ 、 $neighbors_{GJ}$ 取不同值时都会有该情况。其效果如下图所示:




图 4: fig:white-1-0.1-1-0.1




图 5: fig:white-1-0.1-1-0.9

3.2.2 $neighbors_{GJ}$ 、 $weight_{GJ}$ 影响发放数目以及同步情况

$neighbors_{GJ}$ 、 $weight_{GJ}$ 会影响神经元的发放数目以及同步情况，该参数越大则越同步，发放神经元越少。其效果如下：




图 6: fig:white-4-0.1-1-0.1




图 7: fig:white-4-0.3-1-0.1